

INSTITUTO TECNOLÓGICO DE AERONÁUTICA



Cássio dos Santos Sousa

Resolução otimizada de problemas com uso de algoritmos
evolutivos

Trabalho de Graduação
2016

Computação

Sumário

1	Introdução	p. 3
1.1	Motivação	p. 5
1.2	Objetivo	p. 5
1.3	Abordagem	p. 5
	Referências	p. 7

1 Introdução

A resolução de diversos problemas se dá na forma de algoritmos, de instruções bem definidas. No entanto, alguns algoritmos podem pedir inúmeras instruções até concluírem, o que pode até mesmo inviabilizar a solução encontrada. A Inteligência Artificial pode atuar sobre tais problemas de modo a interagir com o problema e aprender com ele a encontrar uma solução. Ótimos candidatos a esta tarefa são os chamados *algoritmos evolutivos (AE)*.

Algoritmos evolutivos são aqueles que se baseiam nos princípios de evolução natural da Biologia, e são aplicados em um modo particular de solução de problemas: o da tentativa-e-erro. Tais algoritmos possuem um framework atuante sobre diferentes *gerações* de um problema, por meio da alteração ou manutenção dos seres existentes na *população* (4). A população, em termos computacionais, pode ser vista como o conjunto de parâmetros de interesse retornados pelo problema, enquanto uma geração seria a população resultante de um ciclo de iterações do AE sobre o problema. Tal framework pode ser visto na figura 1.

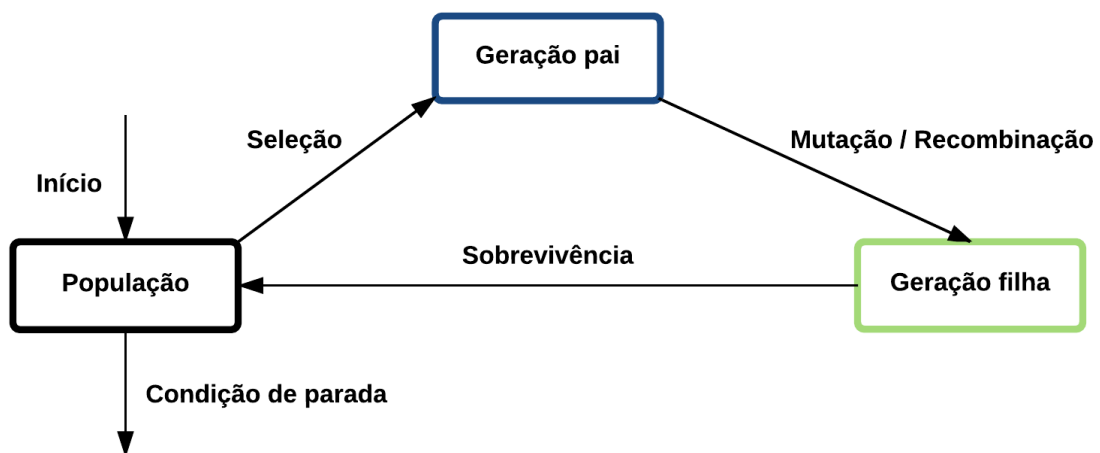


Figura 1: Framework de um algoritmo evolutivo.

Similar ao processo evolutivo, seus componentes principais são as operações de variação (mutação e recombinação) e de seleção (seleção da geração pai e sobrevivência da geração filha), chamados aqui simplesmente de *operações de evolução* (3). É possível ver a *mutação* como a atribuição de um (novo) valor aleatório. A *recombinação* atribuiria o valor médio de uma amostra da população. *Seleção* envolve uma escolha a dedo dos melhores exemplares, e *sobrevivência* envolve a rejeição de um exemplar que não seja tão bom.

Em termos de implementação, o AE deve ser tal que, uma vez aplicado sobre uma população, o desenvolvimento sequencial de gerações é feito automaticamente. Para isso, é necessário passar por quatro etapas (3):

- [1] Implementação do AE e de suas operações de evolução;
- [2] Implementação de problemas compatíveis com a aplicação do AE;
- [3] Otimização do AE quando aplicado a um problema;
- [4] Definição e utilização da função utilidade do AE.

Para [1], pensando que mais de um problema se utilizará do AE, e que cada problema terá populações de complexidades diferentes. É necessário implementar operações de evolução diferentes para cada tipo de população, mas que obedeçam sempre à mesma sequência de execução.

Para [2], é necessário não só deixar a população de um problema acessível ao AE, mas também dizer ao problema quão próxima de uma solução uma geração se encontra, ou quão melhor é uma geração frente às demais. Tal escala é trazida por uma função de *fitness*. Por exemplo, se um problema envolver o encontro das raízes de um polinômio, uma boa função de fitness para um indivíduo x_k da população poderia ser definida por $|f(x_k)|$, indicando uma melhor solução se o valor obtido for menor ou próximo de 0.

Para [3], é possível associar a expressividade das diferentes operações de evolução a valores numéricos (normalmente indo de 0 - sem expressão - a 1 - expressividade máxima). Tais parâmetros, chamados de *parâmetros de evolução*, são comumente representados por vetores e ditam como o AE agirá sobre um problema. Um bom ajuste destes parâmetros é fundamental para o encontro de boas soluções e uma convergência rápida do algoritmo (2).

No entanto, obter um bom vetor de parâmetros não é uma tarefa simples, e simplesmente “chutar” valores já foi comprovado ser algo ineficiente (7). Tal tarefa é comumente

deixada para os algoritmos de ajuste ou de *tuning*, os quais são executados sobre o AE antes de se analisar a aplicação do mesmo sobre o problema. A etapa [3] se mostra análoga à etapa de treinamento de um algoritmo de aprendizado.

Para [4], após ajustar o vetor de parâmetros de um AE, é necessário não só aplicá-lo ao problema, mas também é necessário verificar a qualidade das soluções obtidas ao longo das gerações. Isso é feito por meio da *função utilidade*, a qual determina valores ou métricas de análise das soluções obtidas para um problema. Como é necessário analisar as respostas obtidas, os parâmetros podem se utilizar da função de fitness do problema.

Como a essência do AE é a tentativa-e-erro, tais métricas advêm de métodos estatísticos, como médias, medianas e desvios padrões, e seus valores são calculados sobre diversas execuções completas do AE sobre um problema. Não é possível, no entanto, atribuir significado a cada uma das métricas, o que pede a obtenção de várias delas em busca de uma análise coerente. Não só isso, se pensarmos em performance, a velocidade de convergência para boas soluções também precisa ser medida (3).

Com as quatro etapas concluídas, aplica-se o AE ao problema de interesse, e os resultados são analisados de acordo com os valores trazidos pela função utilidade.

1.1 Motivação

É difícil por si só garantir que um algoritmo evolutivo encontre boas soluções para os problemas mais simples, dada a natureza de sua implementação. Garantir uma execução eficiente do mesmo é fundamental.

1.2 Objetivo

Este trabalho propôs implementar um algoritmo evolutivo que siga as quatro etapas apresentadas acima, de tal forma que ele seja capaz de atuar sobre problemas determinados e encontrar boas soluções com poucas gerações.

1.3 Abordagem

A proposta foi complexa, pois as quatro etapas de criação do algoritmo são interdependentes. A etapa mais crítica foi a [1], que definiu o AE e o esqueleto de implementação

de todas as outras etapas. As etapas [2] e [3] precisaram ter seus problemas/algoritmos bem definidos desde o início, para não atrapalharem o desenvolvimento em estágios avançados do trabalho. A etapa [4] precisou implementar diversas métricas ao longo de seu desenvolvimento, de modo a trazer as análises mais abrangentes possíveis para os problemas.

Para a etapa [2], foram escolhidos os seguintes problemas:

- **Problema Onemax (5):** dado um conjunto de 100 bits iniciados em 0, o AE deve ser capaz de tornar todos os bits iguais a 1. A função de fitness avalia quantos bits estão iguais a 1 ao final de uma geração (quando maior o valor, melhor, sendo 100 a solução ótima);
- **O problema das 8 rainhas (1):** posicionando oito rainhas inicialmente em posições aleatórias sobre um tabuleiro de xadrez 8x8, o AE deve ser capaz de reposicioná-las de tal forma que uma rainha não seja capaz de atacar as demais. A função de fitness avalia quantas rainhas podem se atacar em uma dada geração (quanto mais próximo de zero, melhor).

Para a etapa [3], optou-se por escolher um algoritmo de tuning vastamente utilizado e comparado com outros em termos de performance para múltiplas literaturas (3, 7). Optou-se então pela implementação do algoritmo CMA-ES, o qual atua sobre o AE e sobre o problema até encontrar valores ótimos para os parâmetros de execução por meio de métodos estocásticos compatíveis com este tipo de problema (6).

Dado também que era necessário analisar os problemas, o trabalho foi dividido em cinco módulos:

1. Implementação do AE e de suas operações de evolução;
2. Implementação dos problemas e de suas funções de fitness;
3. Implementação do algoritmo CMA-ES para tuning do AE;
4. Implementação da função utilidade;
5. Execução completa do AE (precedida de tuning) e análises do AE a partir da função utilidade.

1.4 Plano de Trabalho

Os módulos foram realizados na mesma ordem em que foram elencados, com a expectativa de que as implementações do AE e do algoritmo CMA-ES demorassem mais, pois suas implementações precisariam ser validadas por outros módulos do trabalho.

Referências

- 1 Paul J Campbell. Gauss and the eight queens problem: a study in miniature of the propagation of historical error. *Historia mathematica*, 4(4):397–404, 1977.
- 2 A. E. Eiben, R. Hinterding, and Z. Michalewicz. Parameter control in evolutionary algorithms. *Evolutionary Computation, IEEE Transactions*, 3(2):124–141, 1999.
- 3 A. E. Eiben and S. K. Smit. Parameter tuning for configuring and analyzing evolutionary algorithms. *Swarm and Evolutionary Computation*, 1(1):19–31, 2011.
- 4 A. E. Eiben and J. E. Smith. *Introduction To Evolutionary Computing*, volume 53. Springer-Verlag, 2003.
- 5 P. Giguere and D. E. Goldberg. Population sizing for optimum sampling with genetic algorithms: A case study of the onemax problem. *Genetic Programming*, 98:496–503, 1998.
- 6 Nikolaus Hansen. The cma evolution strategy: a comparing review. In *Towards a new evolutionary computation*, pages 75–102. Springer, 2006.
- 7 K. S. Smit and A. E. Eiben. Comparing parameter tuning methods for evolutionary algorithms. In *Evolutionary Computation, 2009. CEC'09. IEEE Congress*, pages 399–406. IEEE, 2009.